PROJET 3 · OPENCLASSROOMS AI ENGINEER

Anticiper la consommation d'énergie des bâtiments de Seattle

Estimer la consommation d'un bâtiment non résidentiel à partir de ses seules caractéristiques, sans relevé

Angèle GOMIS · Octobre 2026

Un relevé coûte cher : peut-on prédire la consommation ?

Le contexte. Seattle vise la neutralité carbone en 2050 et s'intéresse aux bâtiments non destinés à l'habitation.

Le problème. Les relevés de consommation sont coûteux : tous les bâtiments ne peuvent pas être mesurés.

La mission. Prédire la consommation totale d'énergie d'un bâtiment à partir de ses données structurelles : taille, usage, âge, localisation.

Les attendus. Une analyse exploratoire, la comparaison de plusieurs modèles supervisés, puis les facteurs qui influencent le plus le modèle retenu.

3 376

bâtiments relevés par la ville en 2016, décrits par 46 colonnes

1 668

bâtiments non résidentiels, le périmètre de la mission

1 cible

la consommation totale d'énergie, en kBtu

Hypothèse : uniquement ce qui est connu avant le relevé

Utilisé : la description du bâtiment

- Taille : surface bâtie hors parking, étages, nombre de bâtiments
- Usages : type de bâtiment, usage principal, nombre d'usages
- Âge et localisation : quartier, distance au centre-ville
- Présence d'une source d'énergie : raccordement au gaz ou à la vapeur

Exclu : ce qui n'existe qu'après le relevé

- Consommations par source, intensités (EUI), émissions de CO2
- ENERGY STAR Score, calculé à partir de la consommation mesurée
- Statut de conformité et indicateurs d'incohérence du relevé
- Tout encodage calculé avec la cible avant le découpage

Cible : la consommation totale mesurée, passée au log

Mesurée, pas corrigée

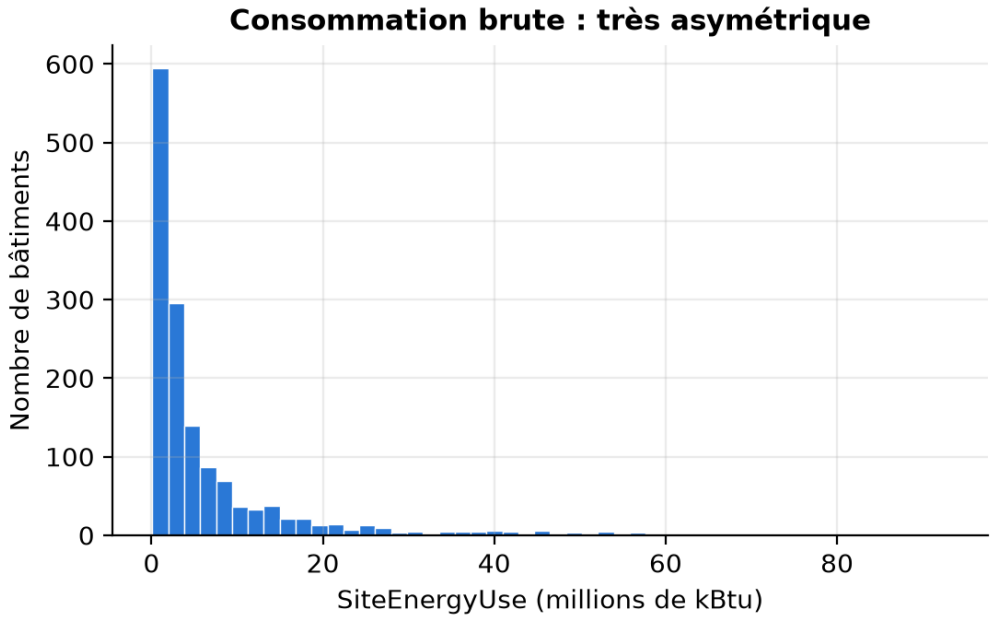
SiteEnergyUse est égale à la somme électricité + gaz + vapeur. La version normalisée météo vaut 0 pour 9 bâtiments qui consomment.

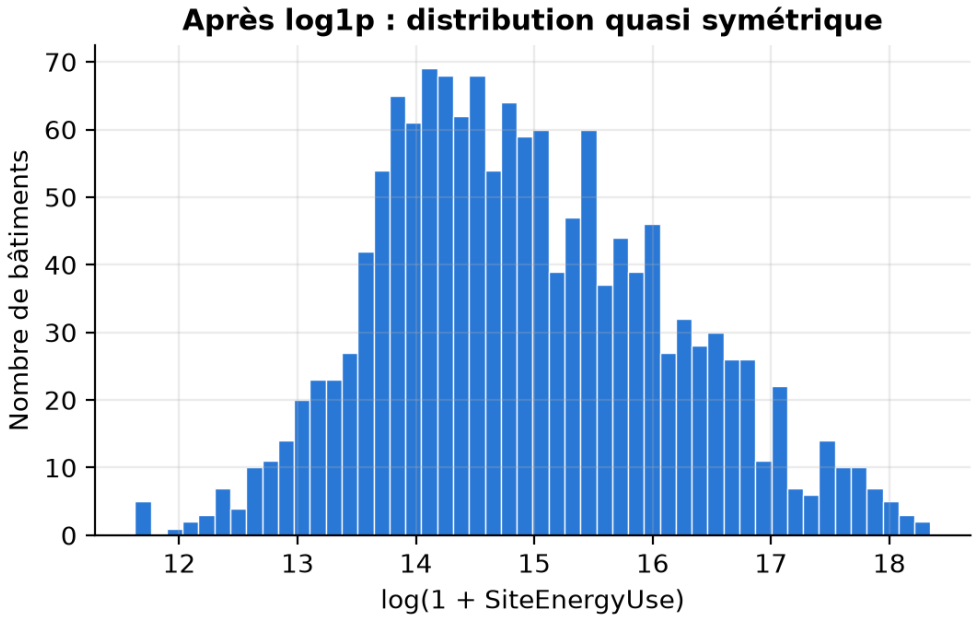
Même météo pour tous

Tous les bâtiments sont à Seattle en 2016 : normaliser la météo ne les différencie pas.

Très asymétrique

Quelques géants tirent la moyenne : modélisation de log(1 + consommation). L'asymétrie passe de 3,6 à 0,3.

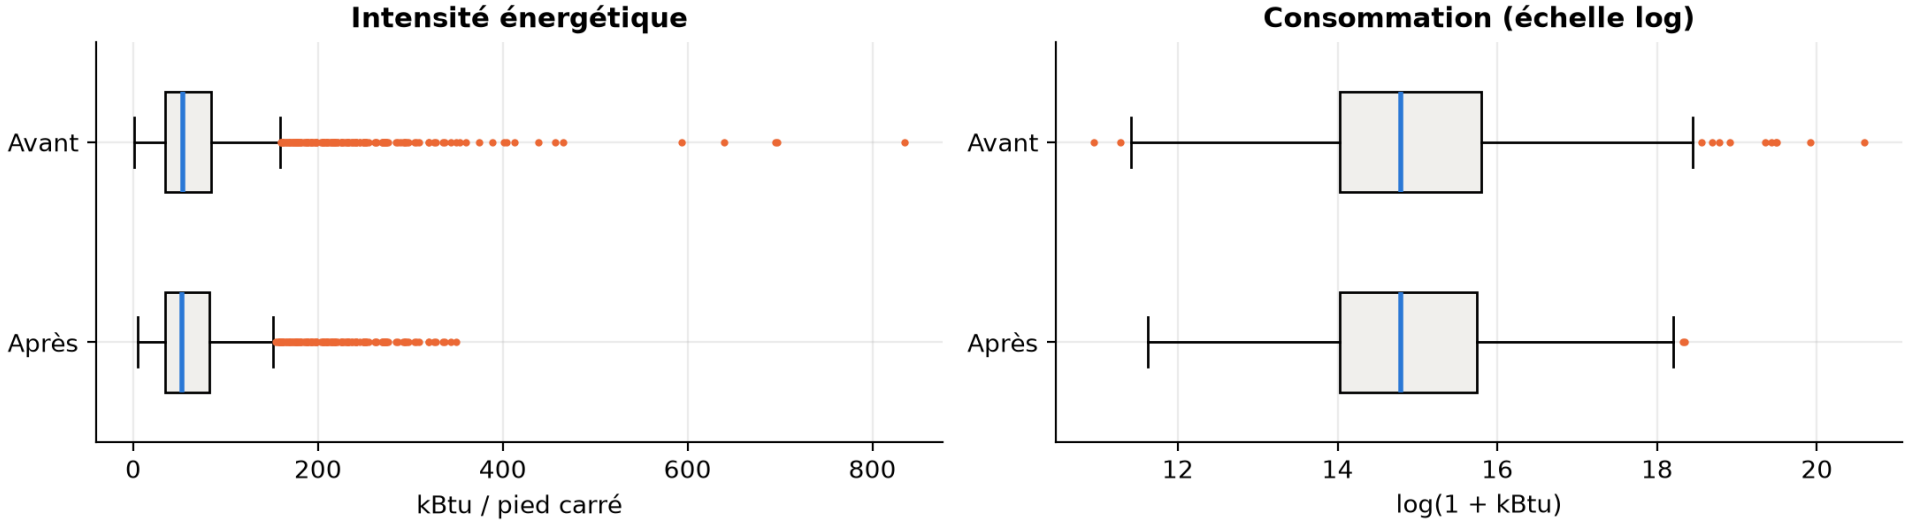




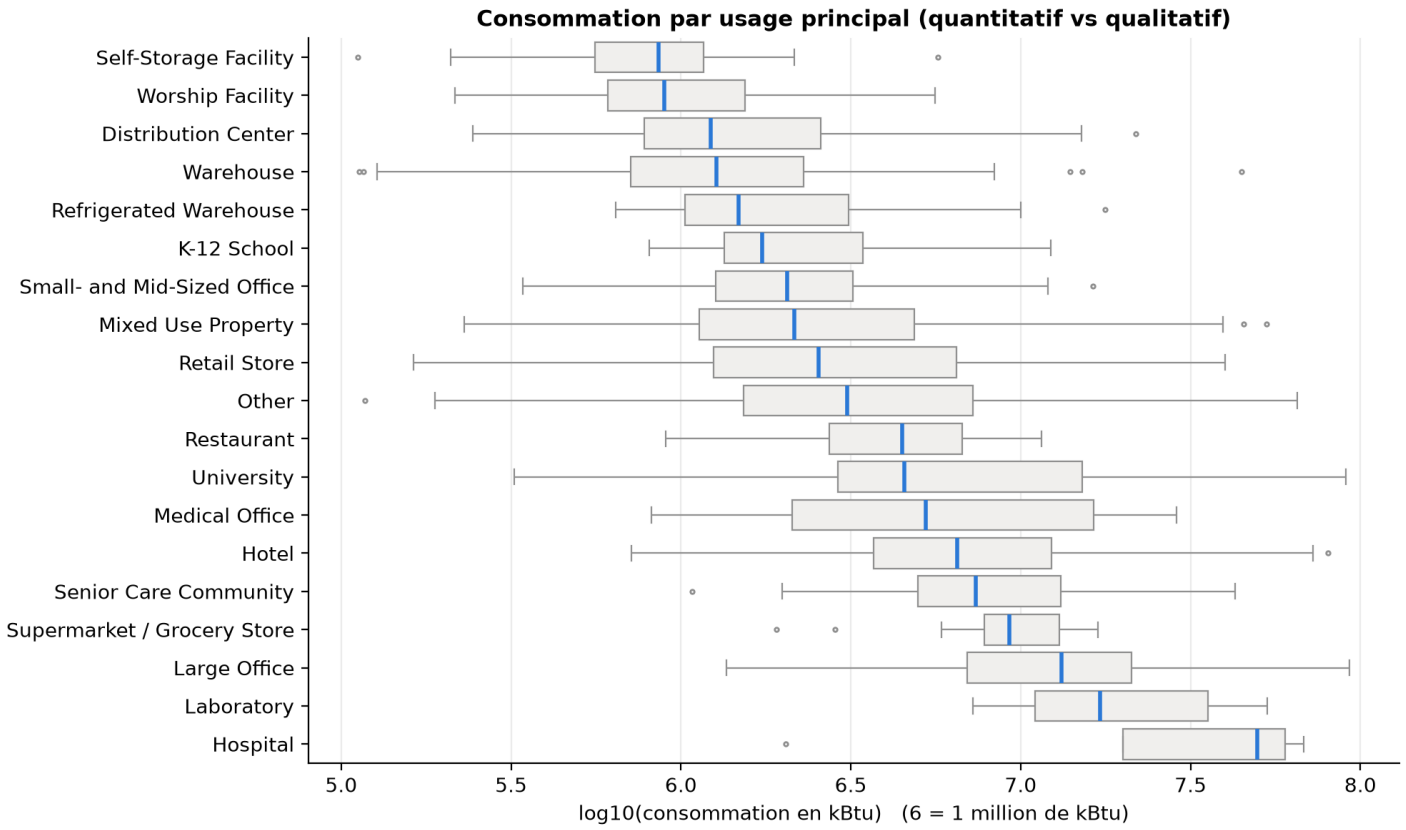
De 3 376 relevés à 1 454 bâtiments fiables

3 376	1 668	1 644	1 525	1 495	1 454
relevés 2016	non résidentiels	hors logements	relevés conformes	hors parkings	hors valeurs extrêmes

Valeurs extrêmes : intensité énergétique entre le 1er et le 99e percentile, et consommation (log) dans [Q1 − 1,5 IQR ; Q3 + 1,5 IQR]. 87 % des bâtiments non résidentiels conservés.



La surface et l'usage expliquent l'essentiel



1

La surface d'abord

En échelle log, la consommation suit presque linéairement la surface bâtie.

2

L'usage multiplie par 10

Intensité médiane : ≈ 20 kBtu/pi² pour un entrepôt, ≈ 250 pour un laboratoire.

3

La vapeur, signe des grands immeubles

Consommation médiane x3,5 pour les bâtiments raccordés. L'âge seul pèse peu.

6 features structurelles créées, doublons supprimés

TEMPORALITÉ

BuildingAge

2016 − année de construction

STRUCTURE

SurfaceParEtage

bâtiment compact ou étalé

USAGES

NbUsages

nombre d'usages, hors parking

USAGES

ProportionUsagePrincipal

part de la surface de l'usage principal

ÉNERGIE (PRÉSENCE)

HasGas · HasSteam

raccordé au gaz ou à la vapeur

LOCALISATION

DistanceCentre_km

distance au centre-ville

Règle des 70 % de corrélation

- Surface bâtie et surface de l'usage principal **(r = 0,94)** : fusionnées dans un ratio
- HasGas et nombre de sources **(r = 0,85)** : nombre de sources supprimé
- Électricité : présente dans 99,8 % des bâtiments, supprimée
- Latitude et longitude : fusionnées dans la distance au centre

La surface reste corrélée à 0,77 avec la cible : c'est le signal que le modèle doit apprendre.

Un protocole qui garde le test intact jusqu'à la fin

1

Découpage

60 / 20 / 20, stratifié sur les déciles de la cible

2

Pipeline

étages imputés par type d'usage, log, StandardScaler, One-Hot

3

Référence

linéaire seule puis optimisée (Ridge), face aux 3 autres familles

4

Finalistes

Ridge et Gradient Boosting optimisés, choix sur le R^2 en validation croisée

5

Test

une seule évaluation, à la toute fin

Métriques

R^2

part de la variance expliquée (en log)

RMSE

erreur quadratique (en log)

MAE

erreur moyenne en kBtu

MdAPE

erreur relative médiane (en %)

Le modèle de référence : l'optimisation apporte +1,5 point

−0,02

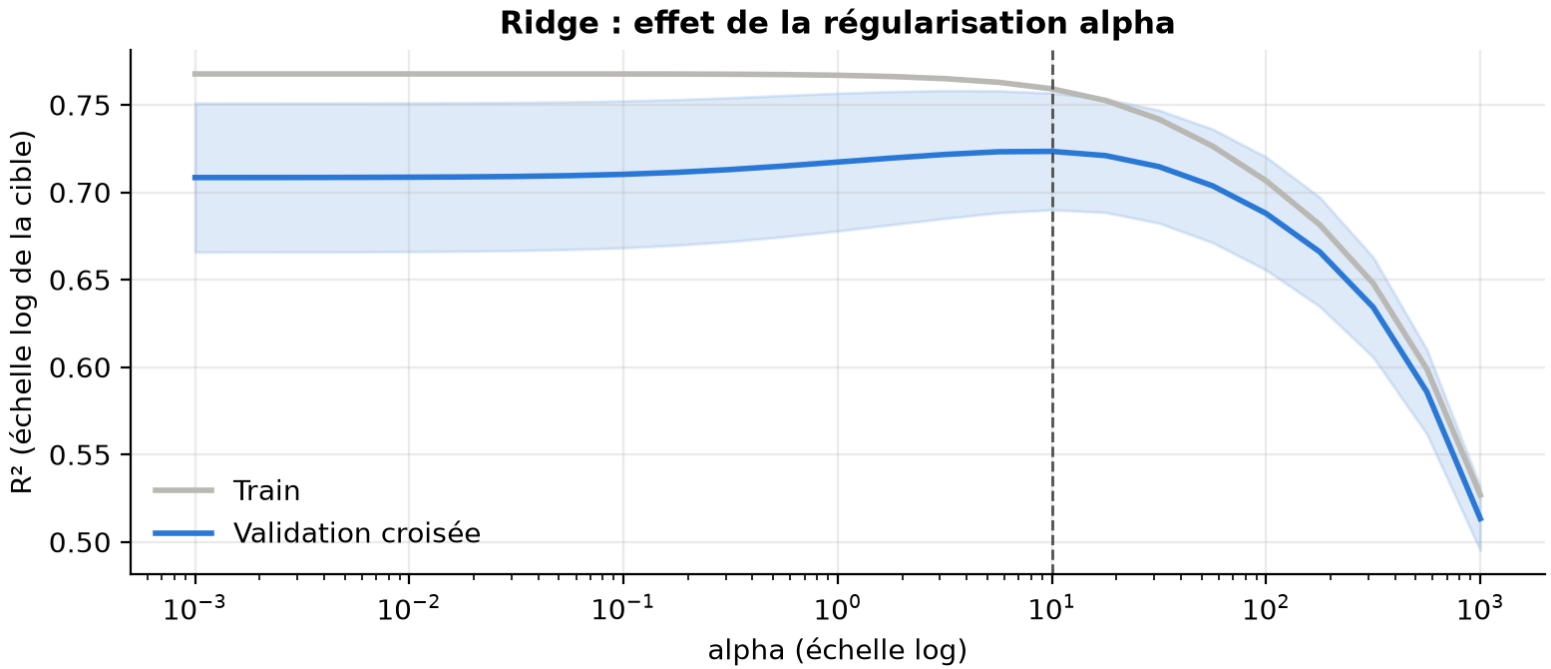
Référence naïve : ne s'optimise pas, c'est le plancher

0,708

Régression linéaire : R^2 en validation croisée

0,723

Ridge optimisée (alpha = 10), plus stable : écart-type 0,043 → 0,033



Lecture : trop peu de régularisation, le modèle colle au train ; trop (alpha au-delà de 100), il devient trop contraint et le R^2 chute partout.

Deux finalistes : Ridge optimisée et Gradient Boosting

Modèle	Famille	R^2 train	R^2 CV (± écart-type)	Erreur médiane CV
Ridge optimisée	**Linéaire régularisé**	**0,76**	**0,723 ± 0,033**	**37 %**
Gradient Boosting	**Ensemble (boosting)**	**0,87**	**0,716 ± 0,030**	**35 %**
SVR (noyau RBF)	SVM	0,84	0,714 ± 0,025	35 %
Régression linéaire	Linéaire	0,77	0,708 ± 0,043	35 %
Random Forest	Ensemble (bagging)	0,96	0,695 ± 0,040	37 %
Référence (moyenne)	Naïf	0,00	−0,019 ± 0,017	76 %

R^2 sur l'échelle log ; erreur médiane = MdAPE, recalculée en kBtu. Moyenne sur 5 folds du train (872 bâtiments). Ridge déjà optimisée, autres modèles par défaut.

Tous battent la référence

Erreur médiane : 35 à 37 % contre 76 % pour la moyenne.

Le Random Forest sur-apprend

0,96 en train, 0,70 en validation croisée.

Linéaire ≈ boosting

En log, la relation surface x usage est presque linéaire.

L'ENERGY STAR Score aiderait, mais c'est une fuite

SANS ENERGY STAR · RETENU

0,72

R^2 en validation croisée

35 %

erreur médiane

AVEC ENERGY STAR · FUITE

0,77

R^2 en validation croisée

30 %

erreur médiane

Pourquoi l'exclure

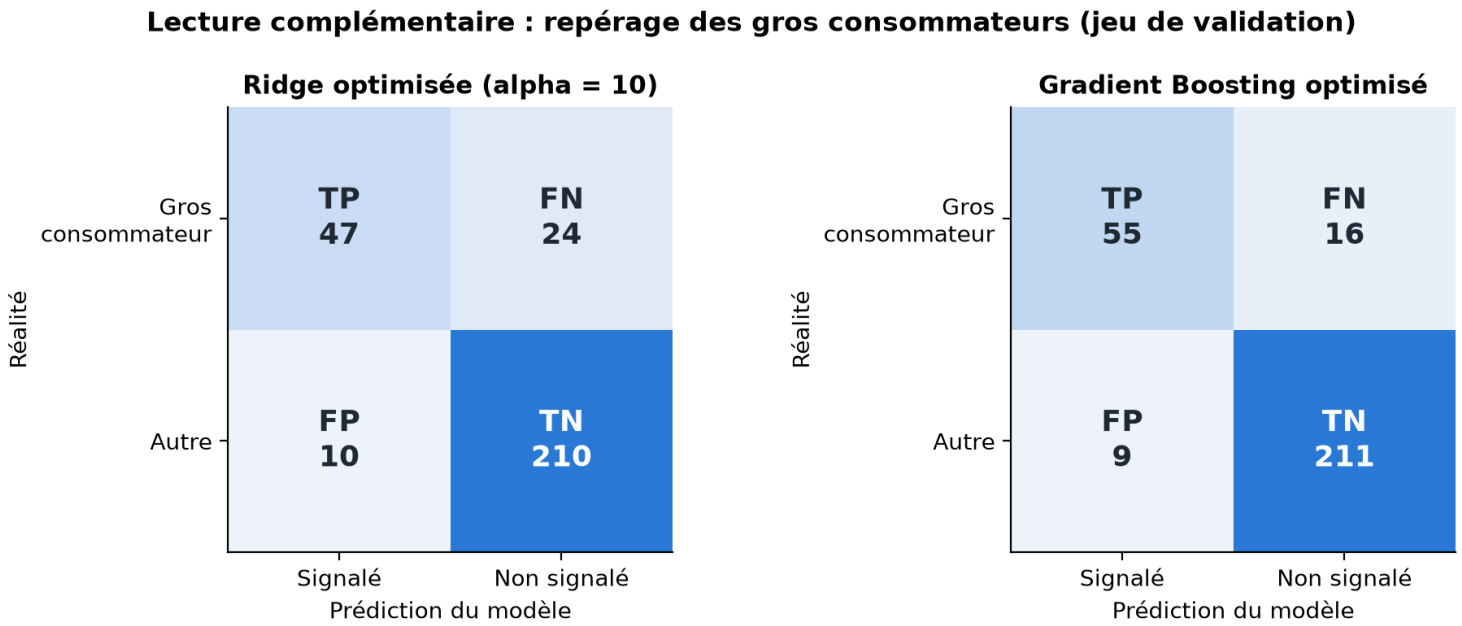
Il est calculé par l'EPA à partir de la consommation mesurée.

Il manque pour un tiers des bâtiments.

Pour un bâtiment jamais relevé, il n'existe pas : impossible de s'en servir pour prédire.

Le gain d'environ 6 points de R^2 est donc le prix de la fuite, pas un vrai progrès.

Deux finalistes à égalité : le Gradient Boosting est retenu



Lecture complémentaire : repérage des gros consommateurs (quart le plus consommateur, plus de 6,9 millions de kBtu par an, seuil fixé sur le train).

Jeu de validation : 71 gros consommateurs sur 291 bâtiments.

Choix : R^2 en validation croisée

Gradient Boosting 0,730 ± 0,028 contre 0,723 ± 0,033 pour la Ridge : l'estimation la plus fiable (5 folds).

Contrôle sur la validation

0,727 pour les deux finalistes : pas de sur-apprentissage. Les deux prédisent aussi bien.

En complément

Le Gradient Boosting repère 55 gros consommateurs sur 71, la Ridge 47.

Sur le test, 8 bâtiments sur 10 à un facteur 2 près

0,76

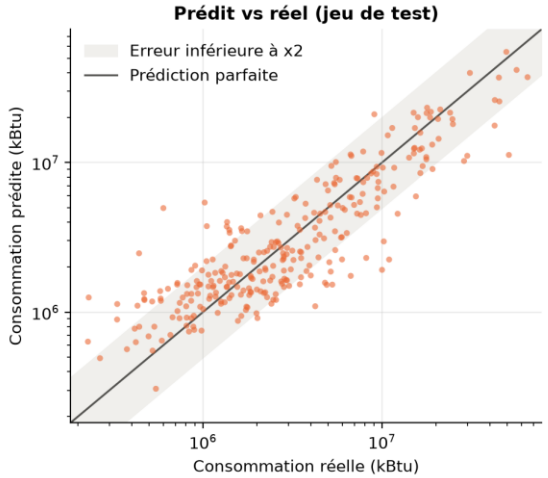
R^2 sur le test (log), proche de la validation croisée

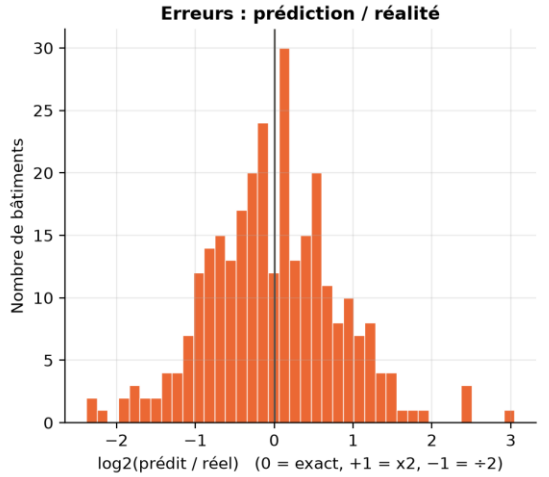
37 %

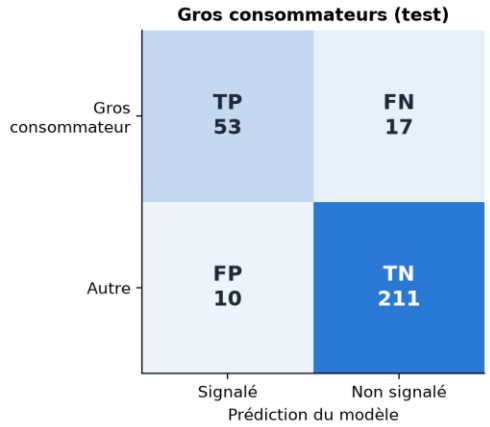
d'erreur médiane : la moitié des bâtiments est estimée à moins de 37 % près

79 %

des bâtiments estimés à un facteur 2 près





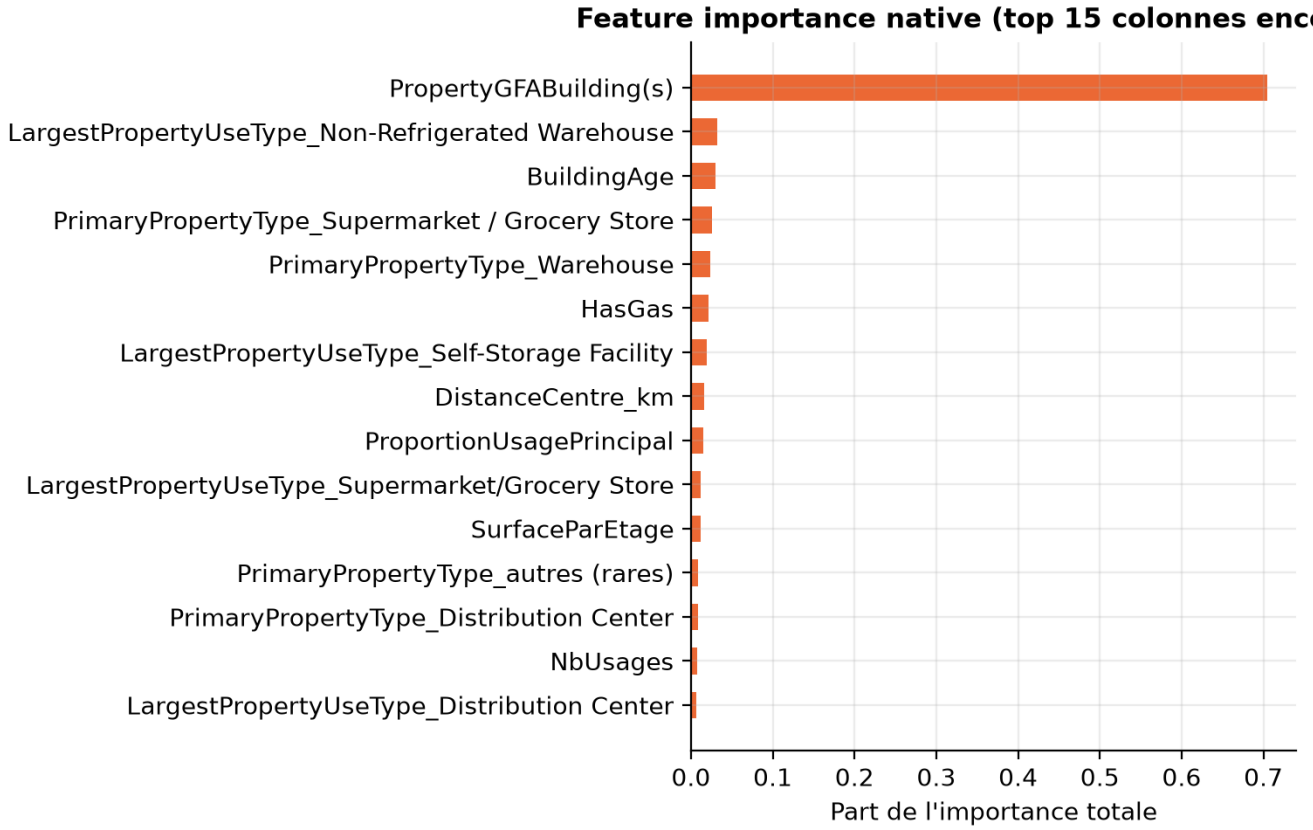


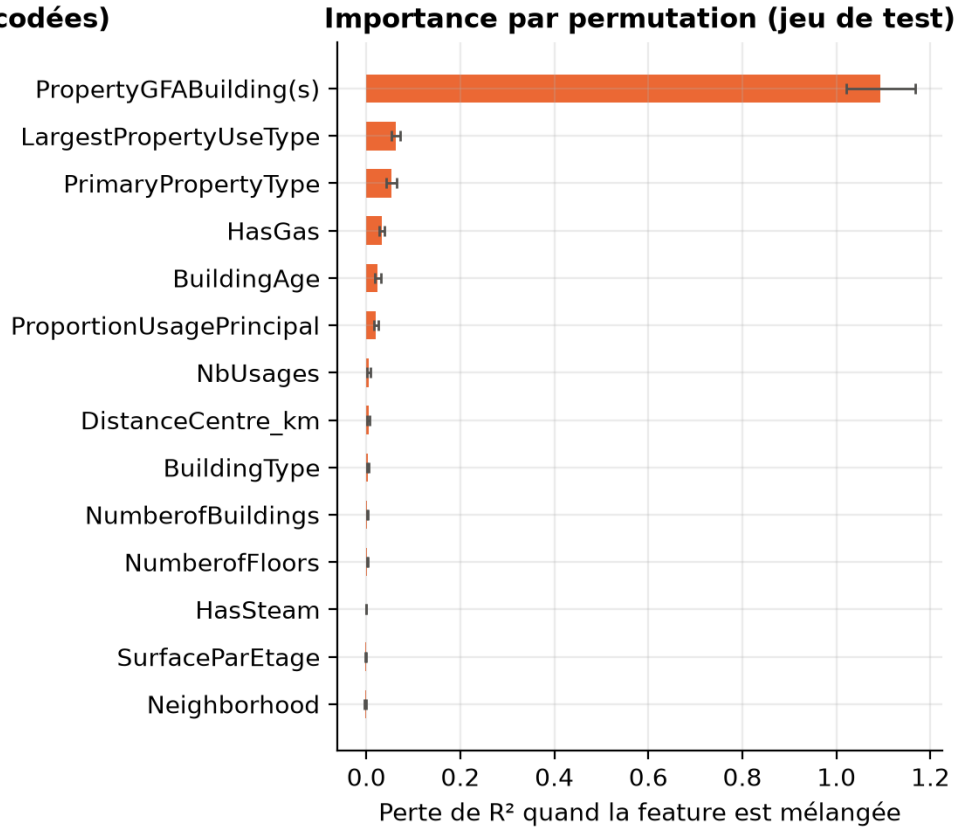
Erreurs équilibrées : 30 surestimations et 30 sous-estimations au-delà d'un facteur 2.

Limites : erreurs plus fortes pour les petits bâtiments et les catégories hétérogènes (« Other », usages mixtes, entrepôts).

En complément : 53 gros consommateurs sur 70 repérés sur le test, avec 10 fausses alertes.

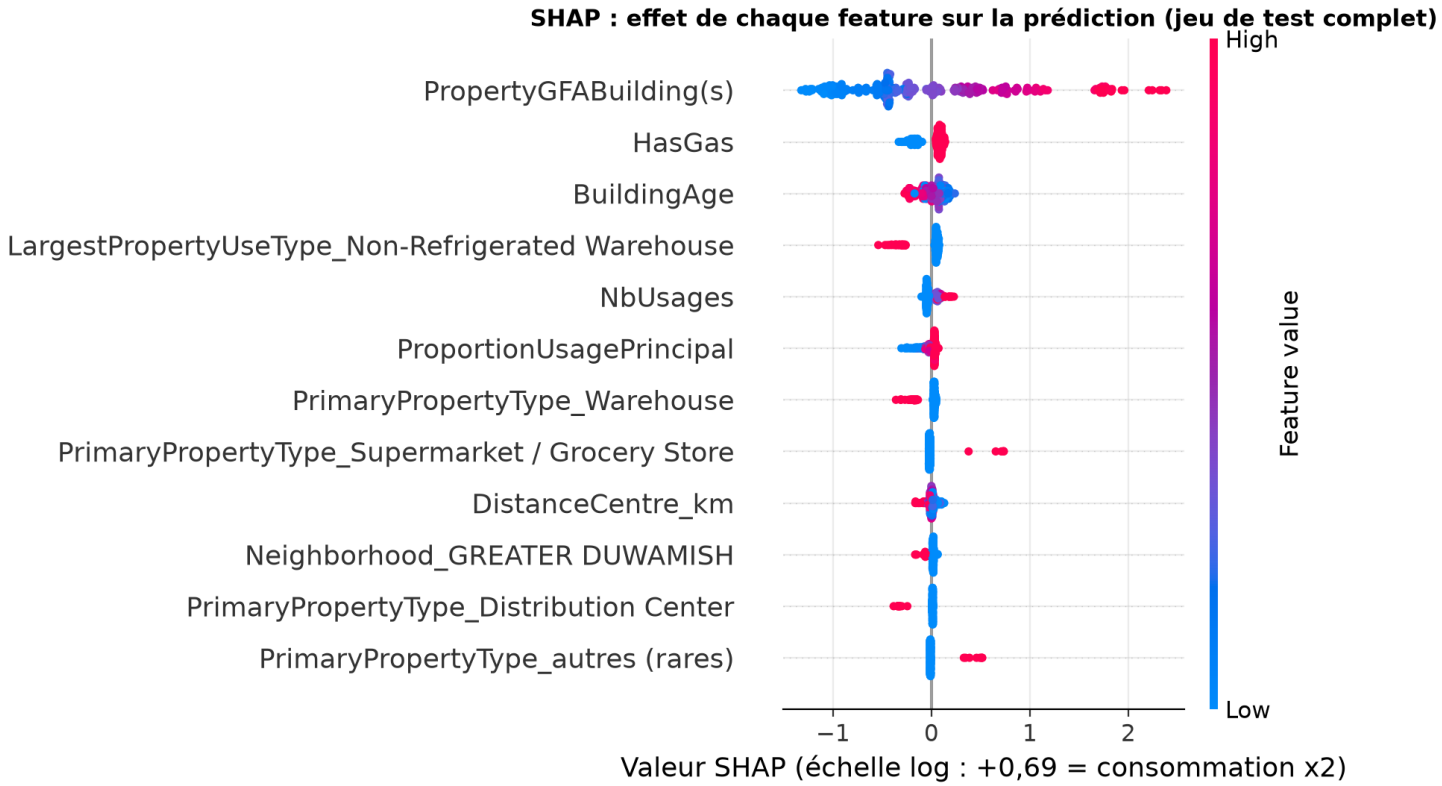
La surface pèse plus que toutes les autres features réunies





Importance par permutation (perte de R^2 sur le test) : surface bâtie 1,09 ≫ plus grand usage 0,06 > usage principal 0,05 > gaz 0,03 > âge 0,02 ≈ part de l'usage principal 0,02.

SHAP : comment chaque feature déplace la prédiction



Lecture : la cible étant en log, une valeur SHAP de +0,69 multiplie la prédiction par 2, et −0,69 la divise par 2.

1. **Surface**
   de ÷3,8 (petits bâtiments) à x11 (très grands)

2. **Gaz**
   le raccordement ajoute environ 9 %

3. **Âge**
   effet modéré, à interpréter sans causalité

4. **Usage**
   entrepôt : environ −30 % ; supermarché : presque x2

Conclusion : prédire la consommation sans relevé

01

Ce que permet le modèle

Estimer la consommation d'un bâtiment jamais relevé : erreur médiane d'environ 37 %, à un facteur 2 près dans 8 cas sur 10. De quoi prioriser les relevés.

02

Ce qui compte le plus

La surface bâtie, de très loin, puis l'usage du bâtiment, le raccordement au gaz et l'âge.

03

Pour aller plus loin

Ajouter d'autres années de relevés, détailler les usages hétérogènes, ajuster le seuil de décision, et créer un second modèle avec l'ENERGY STAR Score pour les bâtiments déjà relevés.

Merci · Questions ?